

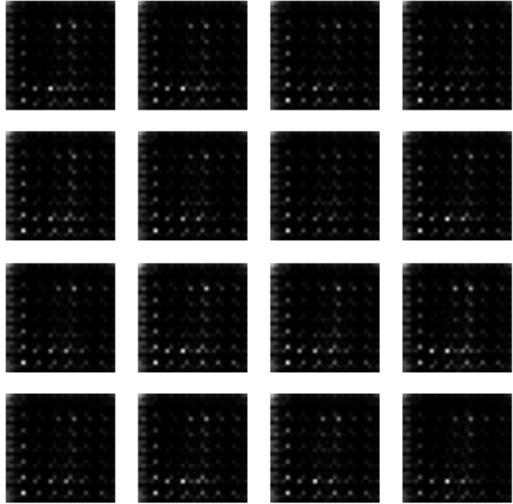
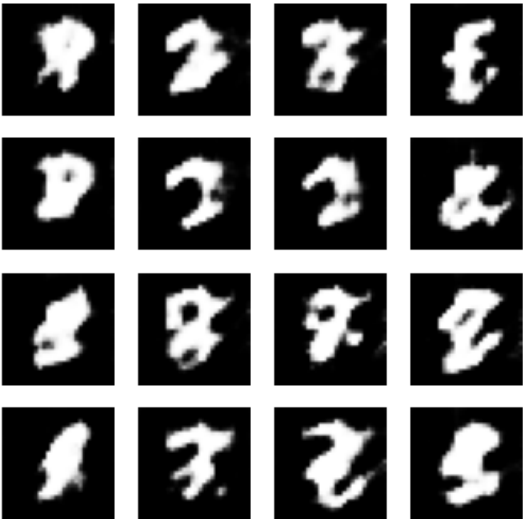
### Estructura de modelo generador $G(x)$

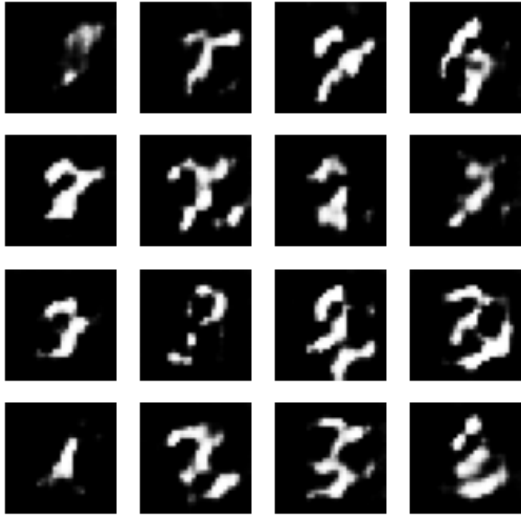

El modelo generador  $G(x)$ , tiene la función de transformar un vector de ruido aleatorio en una imagen que imita las características del conjunto de datos con el que se entrena, en este caso, el conjunto MNIST de dígitos escritos a mano. Comienza su proceso con una capa densa, que toma este vector y lo amplía a una representación tridimensional de  $7 \times 7 \times 256$ . Esta amplificación permite que el modelo tenga un campo inicial más extenso para empezar a formar la imagen. A continuación, estos valores pasan por un proceso de normalización, garantizando que los valores estén en una escala uniforme, y se les aplica una función de activación LeakyReLU. Esta función permite que el modelo maneje mejor los valores negativos y otorga más flexibilidad durante el entrenamiento. A medida que el modelo avanza, utiliza capas de deconvolución, también conocidas como transposiciones convolucionales. Estas capas tienen la capacidad de incrementar la resolución de la imagen mientras mantiene o modifica la profundidad del tensor. Cada una de estas capas va seguida de más normalización y activación LeakyReLU. Al final del proceso, el generador está configurado para producir una imagen de  $28 \times 28$ . Esta imagen resultante tiene valores de píxeles entre -1 y 1, gracias a la función de activación tangente hiperbólica aplicada al final.

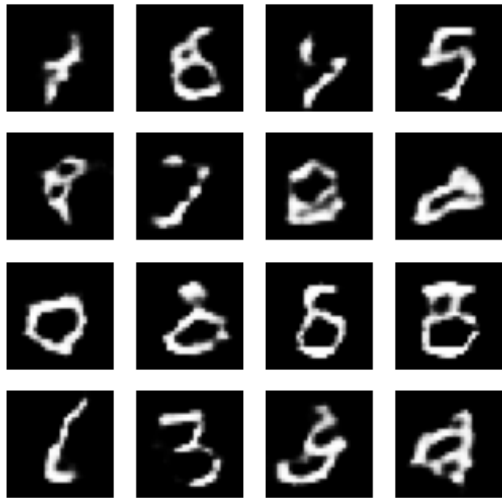
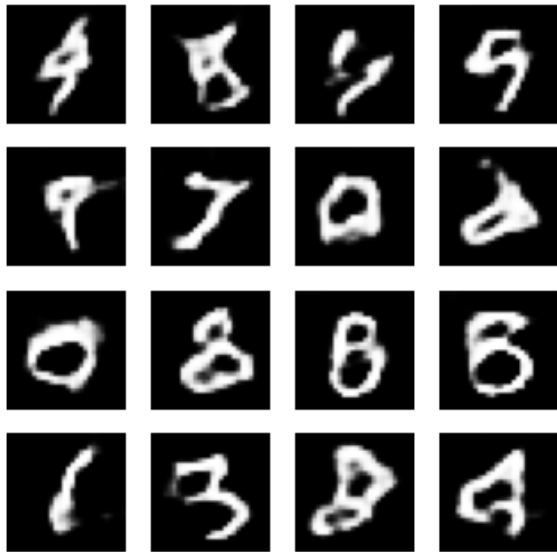
### Estructura de modelo discriminador $D(x)$

En contraste, el discriminador  $D(x)$ , toma parte en el entrenamiento de la red generativa adversaria. Su tarea es discernir si una imagen es auténtica, tomada directamente del conjunto de datos, o si ha sido generada artificialmente por  $G(x)$ . El discriminador comienza su análisis con capas convolucionales que, paso a paso, reducen la resolución de la imagen mientras aumentan la profundidad de la representación del tensor. Estas capas convolucionales están diseñadas para extraer características fundamentales de las imágenes y discernir patrones. Después de cada capa convolucional, se aplica una función de activación LeakyReLU, que, al igual que en el generador, gestiona los valores negativos y otorga flexibilidad al modelo. Además, se introduce un dropout del 30% después de estas capas, una técnica que ayuda a prevenir el sobreajuste, garantizando que el modelo no se vuelva demasiado dependiente de características específicas de las imágenes de entrenamiento. Una vez que el modelo ha procesado la imagen con estas capas, la información se comprime mediante una operación de aplanado. Esta representación aplanada se pasa a una capa densa final, que produce un único valor. Este valor representa la confianza del modelo en que la imagen es real o generada. Es esencial para el proceso de retroalimentación en el entrenamiento de la GAN, guiando las actualizaciones tanto del generador como del discriminador.

Resultados

Epoch 1	
Epoch 10	

Epoch 20	
Epoch 30	

Epoch 40	
Epoch 50	
Gif de todos los resultados	<a href="https://imgur.com/a/Fe6xBeu">https://imgur.com/a/Fe6xBeu</a>

A medida que la GAN avanza en su entrenamiento, se observa cambios en la calidad de las imágenes generadas. Durante las primeras épocas, las imágenes producidas no son tan claras, mostrando ruido aleatorio. Sin embargo, a medida que el generador y el discriminador interactúan y aprenden mutuamente, la claridad y la precisión de las imágenes mejoran progresivamente. Al alcanzar las épocas intermedias, comienzan a surgir características y formas que se asemejan a las del conjunto de datos objetivo, aunque todavía pueden presentar imperfecciones o incoherencias. Finalmente, en las etapas avanzadas del entrenamiento, las imágenes generadas se vuelven cada vez más claras, detalladas y coherentes, llegando a un punto en el que pueden ser prácticamente indistinguibles de las imágenes reales.