

Universidad del Valle de Guatemala  
Facultad de ingeniería



Deep Learning y Sistemas Inteligentes  
Laboratorio 7

Jun Woo Lee  
Andrés de la Roca

Guatemala, 2023

## **Sistema de recomendación de red neuronal basada en contenido**

Estos tipos de sistema de recomendación basados en contenido son principalmente utilizados para realizar recomendaciones en base a los datos encontrados en el dataset como tal y sin tratar de realizar operaciones que relacionan explícitamente una variable como el usuario con el libro directamente, sino que esta relación sea más implícita y que a partir de esto realice las predicciones necesarias para ofrecer una recomendación.

Por lo general este tipo de sistema de recomendación basado en redes se basa alrededor del siguiente bucle de funcionamiento:

**Representación del contenido:** En primer lugar, se necesita una representación detallada y estructurada del contenido de los elementos que se van a recomendar. Por ejemplo, si se trata de recomendación de películas, esto podría incluir características como género, director, actores, clasificación por edades, sinopsis, etc. Para recomendación de productos, las características podrían ser el tipo de producto, marca, precio, características técnicas, etc.

**Extracción de características:** Luego, se extraen características relevantes del contenido. Esto puede implicar el procesamiento de lenguaje natural (NLP) para analizar el texto o el uso de técnicas específicas para otros tipos de contenido, como imágenes o audio. Por ejemplo, en el caso de películas, se podría utilizar NLP para analizar las sinopsis y extraer palabras clave relacionadas con la trama y el género.

**Construcción de la red neuronal:** Se construye una red neuronal que toma estas características como entradas. La arquitectura de la red puede variar, pero comúnmente se utilizan capas de neuronas y técnicas de aprendizaje profundo, como redes neuronales convolucionales (CNN) para procesar imágenes o redes neuronales recurrentes (RNN) para procesar secuencias de texto.

**Aprendizaje:** La red neuronal se entrena utilizando un conjunto de datos de entrenamiento que incluye ejemplos de elementos y las características asociadas a ellos. La red aprende a mapear las características del contenido según las preferencias de los usuarios, de modo que pueda predecir qué elementos son más propensos a ser apreciados por un usuario en función de sus características.

**Generación de recomendaciones:** Una vez que la red está entrenada, se puede utilizar para generar recomendaciones para un usuario específico. Dado un usuario y sus preferencias, la red puede evaluar las similitudes entre el contenido disponible y las preferencias del usuario, y luego recomendar elementos que se ajusten a esas preferencias en función de su contenido.

## Red implementada

Entradas:

items\_input y users\_input son las entradas del modelo para representar los libros y los usuarios, respectivamente.

shape=(x\_item.shape[1]) y shape=(x\_user.shape[1]) indican las dimensiones de las entradas, que están determinadas por la forma de los datos de entrada.

Capas ocultas para la representación de libros y usuarios:

Para los elementos, se utiliza una capa densa (fully connected) con 32 neuronas y activación ReLU (Rectified Linear Unit) para transformar la información del elemento (items\_input) en un espacio de representación.

De manera similar, se aplica una capa densa para los usuarios (users\_input) con la misma configuración.

Normalización L2:

Después de la representación, se realiza una normalización L2 en los vectores resultantes de elementos y usuarios utilizando tf.linalg.l2\_normalize. Esto normaliza los vectores para que tengan una longitud euclidiana igual a 1 en el espacio vectorial. Esto puede ser útil para asegurarse de que los vectores tengan magnitudes similares y simplificar el cálculo de similitud entre elementos y usuarios.

Cálculo del producto punto (Dot product):

Se calcula el producto punto entre los vectores normalizados de elementos (items\_norm) y usuarios (users\_norm) utilizando layers.Dot(axes=1). Esto mide la similitud entre los vectores de elementos y usuarios normalizados. Un resultado más alto indica una mayor similitud entre el usuario y el elemento.

Modelo de salida:

La salida del modelo es un solo valor que representa la estimación de la preferencia del usuario por el elemento. Cuanto mayor sea este valor, mayor será la estimación de preferencia.

Compilación del modelo:

Se compila el modelo utilizando la función de pérdida 'mean\_squared\_error' (error cuadrático medio), que es comúnmente utilizada en problemas de regresión. El optimizador utilizado es Adam con una tasa de aprendizaje de 1e-4.

## Resultados

Posteriormente a entrenar el modelo por 5 epochs, recibiendo como input los tipos de usuarios y libros dentro del dataset se obtuvo la siguiente información

```
Epoch 1/5
35931/35931 [=====] - 113s 3ms/step - loss: 0.1331
Epoch 2/5
35931/35931 [=====] - 108s 3ms/step - loss: 0.1272
Epoch 3/5
35931/35931 [=====] - 108s 3ms/step - loss: 0.1248
Epoch 4/5
35931/35931 [=====] - 110s 3ms/step - loss: 0.1231
Epoch 5/5
35931/35931 [=====] - 110s 3ms/step - loss: 0.1218
```

Como se puede observar, los valores de pérdida se mantienen dentro de un rango similar, lo que nos hace observar que este tipo de sistema quizás no sea el mas efectivo, ya que basicamente se esta “estancando” luego de realizar la primera epoch y no está aprendiendo mucho como para poder realizar predicciones/recomendaciones lo suficientemente relevantes al usuario, esto probablemente se deba a que al no realizar relaciones explícitas entre libros, ratings y usuarios se pierdan ciertos patrones útiles para poder realizar las recomendaciones.

Vale la pena mencionar que el input explícito que se usa en este modelo es el lugar de origen del usuario y su edad, y a partir de esto realiza las recomendaciones. Como se puede observar en la siguiente tabla ( Para una persona de 25 años de Barcelona, España ) se realizan las siguientes recomendaciones, las cuales tienen cierto sentido en recomendarse, ya que básicamente son libros de más o menos la época en la que nació esta persona ( Con referencia a las últimas entradas de fecha del dataset ). Sin embargo, por esta poca relación que hay entre los libros y los usuarios debido a la naturaleza de este tipo de sistema de recomendación no se puede juzgar si estas recomendaciones son algo que le gustaría al tipo de usuario descrito.

```
df_books.sort_values('preds', ascending=False).head(10)
```

	ISBN	Book-Title	Book-Author	Year-Of-Publication	Publisher	Image-URL-S
239452	2259191630	El Árbol de las Aventuras africanas	Ryszard Kapuscinski	2000	Omnibus	<a href="http://images.amazon.com/images/P/2259191630.0...">http://images.amazon.com/images/P/2259191630.0...</a>
227007	3423129441	SÄÄntliche Werke. Zweisprachige Ausgabe: Fra...	Francois Villon	2002	Dtv	<a href="http://images.amazon.com/images/P/3423129441.0...">http://images.amazon.com/images/P/3423129441.0...</a>
28324	2203001143	Tintin Au Pays de L'Or Noir / Land of Black Go...	Herge	1999	Distribooks Intl	<a href="http://images.amazon.com/images/P/2203001143.0...">http://images.amazon.com/images/P/2203001143.0...</a>
55611	848328006X		George Orwell	1997	Plaza & James Editores, S.A.	<a href="http://images.amazon.com/images/P/848328006X.0...">http://images.amazon.com/images/P/848328006X.0...</a>
119923	8483002507	El misteri de Beràn (Col·lecció d'Àstica)	Jordi Mata	1997	Columna	<a href="http://images.amazon.com/images/P/8483002507.0...">http://images.amazon.com/images/P/8483002507.0...</a>
204935	0914610589	Smart Like Me: High School Age Writing from th...	Mark Pawlak	1995	Hanging Loose Press	<a href="http://images.amazon.com/images/P/0914610589.0...">http://images.amazon.com/images/P/0914610589.0...</a>
213685	074750797X	Splitting the Atom	Stephen Amidon	1991	Bloomsbury Publishing Plc	<a href="http://images.amazon.com/images/P/074750797X.0...">http://images.amazon.com/images/P/074750797X.0...</a>
198270	0756603005	Scooby-Doo! The Essential Guide	Glenn Dakin	2004	DK Publishing Inc	<a href="http://images.amazon.com/images/P/0756603005.0...">http://images.amazon.com/images/P/0756603005.0...</a>
167463	207039252X	Anna KarÄ? Ä@nine	LÄÄ@on TolstoÄÄ	1994	Gallimard	<a href="http://images.amazon.com/images/P/207039252X.0...">http://images.amazon.com/images/P/207039252X.0...</a>
136016	3551553068	Fantastische Tierwesen Und Wo Sie Zu Finden Si...	J. K. Rowling	2002	Distribooks	<a href="http://images.amazon.com/images/P/3551553068.0...">http://images.amazon.com/images/P/3551553068.0...</a>

## Sistema de recomendación de red neuronal basada en filtros colaborativos

Los sistemas de recomendación basados en filtros colaborativos son esenciales en la era digital, impulsando la personalización y mejorando la experiencia del usuario en plataformas de comercio electrónico, servicios de streaming y bibliotecas en línea. A diferencia de los sistemas basados en contenido, que se centran en las propiedades intrínsecas de los ítems, los filtros colaborativos se apoyan en las interacciones y opiniones compartidas entre usuarios para generar recomendaciones. Este enfoque se beneficia de las valoraciones y comportamientos de los usuarios, tejiendo una red de preferencias compartidas que sirve como fundamento para predecir el gusto de elementos no descubiertos.

La implementación de nuestro modelo colaborativo comienza con la importación de herramientas analíticas y de aprendizaje automático, preparando el terreno para un procesamiento de datos sofisticado y el desarrollo de un modelo de red neuronal. Con conjuntos de datos que encapsulan las calificaciones de libros, los detalles demográficos de los usuarios y la información bibliográfica, el modelo se enfrenta al desafío de destilar patrones significativos de un océano de datos.

El preprocesamiento es un paso crucial, donde se emplean imputadores para tratar los datos faltantes y se aplica la normalización a las calificaciones de los libros para garantizar la uniformidad en la entrada del modelo. La división estratégica del conjunto de datos asegura que tengamos una porción reservada para la validación del modelo, manteniendo un equilibrio entre el aprendizaje y la evaluación.

La arquitectura del modelo es una construcción elegante de capas de entrada que representan a los usuarios y los libros, pasando a través de embeddings y capas densas que se funden en un aprendizaje profundo. La red se compila con un enfoque en la minimización del error

cuadrático medio, y se entrena en una serie de iteraciones que afinan su capacidad para predecir las preferencias de los usuarios.

A través del entrenamiento, se observa una disminución en la pérdida de entrenamiento, aunque con signos de sobreajuste dada la creciente pérdida de validación. A pesar de esto, el modelo logra producir recomendaciones para un nuevo usuario, prediciendo calificaciones para una vasta colección de libros y destacando aquellos con las valoraciones más prometedoras.

El resultado es un sistema que no solo recomienda libros basados en calificaciones pasadas sino que también descubre nuevas conexiones entre gustos y preferencias. Este modelo colaborativo se convierte en un aliado para los usuarios, guiándolos a través de un laberinto de opciones literarias y abriendo puertas a mundos aún no explorados por sus ojos lectores.

### Red implementada

Entradas del Modelo:

El sistema de recomendación que se despliega en este modelo utiliza un enfoque de filtros colaborativos para anticipar las preferencias de los usuarios basándose en interacciones pasadas. El modelo comienza con dos capas de entrada, `user_id_input` y `book_id_input`, que captan los identificadores numéricos únicos para usuarios y libros, respectivamente. Estos identificadores son fundamentales para el aprendizaje colaborativo, ya que conectan a cada usuario y libro con su historial de interacciones y calificaciones dentro del conjunto de datos.

Red Neuronal Densa:

La arquitectura del modelo de recomendación se profundiza a través de una red neuronal densa, una estructura clave para interpretar las interacciones entre usuarios y libros. La información codificada en el producto punto de los vectores de incrustación aplanados se canaliza hacia una red de capas densas. La primera capa de esta red posee 128 neuronas y emplea la función de activación 'relu'. Esta elección es deliberada, ya que la 'relu', o unidad lineal rectificada, introduce no linealidades en el modelo, lo cual es esencial para capturar y modelar patrones complejos y no lineales presentes en los datos.

El flujo de datos concluye en la capa de salida del modelo, que utiliza una función de activación 'sigmoid'. Esta función es particularmente importante ya que comprime los valores de salida del modelo a un rango entre 0 y 1. Esta restricción es interpretada como una probabilidad, con el valor de salida representando la probabilidad estimada de que un libro sea del agrado del usuario. De esta manera, el modelo no solo puede predecir si a un usuario le gustará un libro o no, sino que también puede ordenar los libros según la preferencia predicha, permitiendo así una clasificación personalizada y jerarquizada de recomendaciones para cada usuario.

Compilación del modelo:

El ensamblaje del modelo culmina con la definición precisa de las capas de entrada y salida, seguido de una fase de compilación que pone énfasis en la precisión predictiva. Se selecciona el optimizador Adam para esta tarea, aprovechando su eficacia y su habilidad intrínseca para ajustar las tasas de aprendizaje de forma autónoma. Esta elección es estratégica, con una tasa de aprendizaje inicial establecida en 0.001, lo cual promueve un equilibrio óptimo entre la rapidez de aprendizaje y la estabilidad en la convergencia del modelo.

La función de pérdida seleccionada, 'mean\_squared\_error', actúa como un barómetro de la precisión del modelo, proporcionando una medida cuantitativa de la discrepancia entre las calificaciones predichas por el modelo y las calificaciones reales otorgadas por los usuarios. El proceso de minimización de esta pérdida es iterativo y refina las incrustaciones y los pesos de las capas densas, ajustándolos en respuesta a los patrones encontrados en los datos de calificación. A medida que el modelo se entrena, la pérdida de entrenamiento tiende a disminuir, indicativo de un aprendizaje efectivo. No obstante, se debe mantener una vigilancia constante sobre la pérdida de validación para prevenir el sobreajuste, asegurando que el modelo mantenga su capacidad de generalizar y no solo memorice los datos de entrenamiento.

La fase final de evaluación del modelo es crítica; en ella, se contrastan las predicciones generadas por el modelo con las calificaciones reales contenidas en un conjunto de validación independiente. Este proceso de validación es crucial, ya que garantiza la robustez del modelo y su capacidad para generalizar más allá de los datos de entrenamiento. Solo a través de esta evaluación rigurosa se puede confirmar que el modelo es capaz de predecir con precisión las preferencias de los usuarios en escenarios reales, y no solo bajo condiciones controladas de entrenamiento.

## Resultados

Posteriormente a entrenar el modelo por 5 epochs se obtuvo la siguiente información

```
Epoch 1/5
11498/11498 [=====] - 485s 42ms/step - loss: 0.1462 - val_loss: 0.1405
Epoch 2/5
11498/11498 [=====] - 485s 42ms/step - loss: 0.0644 - val_loss: 0.1776
Epoch 3/5
11498/11498 [=====] - 486s 42ms/step - loss: 0.0337 - val_loss: 0.1773
Epoch 4/5
11498/11498 [=====] - 487s 42ms/step - loss: 0.0237 - val_loss: 0.1812
Epoch 5/5
11498/11498 [=====] - 479s 42ms/step - loss: 0.0185 - val_loss: 0.1946
```

El análisis de los resultados del entrenamiento del modelo de filtrado colaborativo revela una tendencia preocupante en cuanto a la eficacia del sistema de recomendación. Los valores de pérdida disminuyen significativamente después de la primera época, pasando de 0.1462 a 0.0644, lo que indica un aprendizaje inicial positivo. Sin embargo, al avanzar en las épocas subsiguientes, la pérdida de validación incrementa de 0.1405 a 0.1946, sugiriendo que el modelo mejora su ajuste a los datos de entrenamiento pero a costa de su capacidad para generalizar a datos nuevos, un fenómeno conocido como sobreajuste.

El modelo ha identificado una serie de libros con calificaciones en un rango cercano a 7, lo que sugiere una afinidad moderada hacia estos títulos. Entre las recomendaciones principales, encontramos una variedad de géneros y temas, desde el intrigante "Shameless" hasta la exploración cosmológica en "The Pleiadian Agenda". También se destacan obras como "Introduction to Database Systems", que sugiere una inclinación hacia el aprendizaje técnico o profesional, y "The Bread of Those Early Years", un clásico europeo que podría apelar a un sentido de nostalgia cultural o literaria.

### **¿Qué modelo funciona mejor y por qué?**

El modelo basado en contenido parece funcionar mejor ya que muestra una mejoría constante y requiere menos tiempo por época. Sin embargo, es importante recordar que la calidad de las recomendaciones no siempre se refleja directamente en la pérdida de validación. Las métricas de evaluación cualitativa, como la relevancia de las recomendaciones y la satisfacción del usuario, también son fundamentales para evaluar la efectividad de un sistema de recomendación.